

Informe

Introducción

Los procesos de admisión y nivelación de la Universidad de Guayaquil generan un volumen considerable de consultas repetitivas relacionadas con requisitos, fechas, registro, creación de cuentas, matrícula, aprobación de asignaturas y aceptación de cupos. Gran parte de esta información se encuentra distribuida entre portales institucionales y recursos complementarios, lo que dificulta su consulta rápida y clara por parte de los aspirantes.

Con el fin de atender este problema, se planteó el desarrollo de un agente conversacional en español orientado a responder preguntas frecuentes sobre admisión y nivelación de la UG. El enfoque adoptado se basa en técnicas clásicas de Procesamiento de Lenguaje Natural, centradas en la detección de intenciones y en la recuperación de respuestas predefinidas, sin recurrir a modelos generativos abiertos ni a arquitecturas profundas de aprendizaje.

Objetivo

El objetivo general del proyecto es diseñar e implementar un chatbot académico que identifique la intención del usuario y devuelva respuestas pertinentes sobre los procesos de admisión y nivelación de la Universidad de Guayaquil, utilizando información real de fuentes oficiales y aplicando un mecanismo de fallback para consultas no reconocidas.

De forma específica, el proyecto contempla la recolección de información institucional, el modelado de intenciones y entidades, el preprocesamiento del texto, la representación vectorial mediante TF-IDF, la comparación por similitud coseno y la evaluación del comportamiento general del agente.

Fuentes de Información

El enunciado del parcial establece que las intenciones y flujos de consulta deben fundamentarse estrictamente en fuentes oficiales y datos actualizados de la institución. En el notebook del proyecto se observan como referencias principales el portal de admisión, la página de nivelación, el calendario académico, el portal general de admisión y el repositorio del proyecto en GitHub.

Las fuentes visibles en el cuaderno son:

- Portal de admisión UG: <https://admision.ug.edu.ec/admision/>
- Curso de nivelación UG: <https://admision.ug.edu.ec/nivelacion/>
- Calendario académico: <https://admision.ug.edu.ec/calendario/>
- Portal general de admisión: <https://admision.ug.edu.ec/>
- Repositorio del proyecto: https://github.com/Ivn5739/Proyecto_PLN_P2

Diseño del Agente

El agente conversacional se organiza a partir de un conjunto de intenciones del dominio, cada una asociada a utterances y respuestas predefinidas almacenadas en un archivo estructurado, como JSON o CSV. El requerimiento académico pide definir entre 10 y 15 intenciones principales, suficientes para cubrir los temas más recurrentes de admisión y nivelación.

Además, el sistema debe contemplar extracción de entidades mediante reglas o expresiones regulares. Entre las entidades de interés se incluyen fechas, cédulas, nombres de carreras y términos específicos como “curso de nivelación” o “cupó aceptado”.

La arquitectura general sigue una secuencia clara: primero se recolectan y estructuran las utterances del dominio; luego se preprocesan las consultas; posteriormente se representan mediante TF-IDF; después se calcula la similitud coseno entre la consulta y las frases

registradas; y, finalmente, se devuelve la respuesta asociada a la intención con mayor similitud o se activa una respuesta fallback si la confianza es insuficiente.

Preprocesamiento y Representación Textual

El preprocesamiento constituye una etapa fundamental del proyecto. Según el enunciado, el sistema debe convertir el texto a minúsculas, eliminar signos de puntuación y caracteres especiales, tratar acentos, tokenizar, remover stopwords y aplicar lematización o stemming básico.

Estos pasos permiten reducir ruido, unificar variantes lingüísticas y mejorar la coincidencia entre consultas formuladas de manera distinta. En español, esto resulta especialmente útil porque una misma intención puede expresarse con cambios morfológicos, construcciones interrogativas variadas o pequeñas diferencias léxicas.

La representación de las frases debe realizarse con TF-IDF usando unigramas o bigramas. Esta técnica es adecuada porque pondera la importancia de los términos en función de su frecuencia local y de su capacidad para discriminar entre intenciones, lo que mejora la separación entre consultas similares dentro del dominio académico.

Detección de Intenciones y fallback

La detección de intenciones se realiza mediante similitud coseno entre la consulta del usuario y las utterances previamente vectorizadas. Esta medida resulta apropiada para espacios vectoriales dispersos, ya que compara la orientación entre vectores y reduce el efecto de la diferencia de longitud entre frases.

El sistema debe seleccionar la intención con mayor similitud y devolver su respuesta predefinida. Sin embargo, para evitar respuestas incorrectas ante preguntas ambiguas o fuera del alcance del sistema, se incorpora un umbral de confianza. Cuando la similitud máxima no supera

ese umbral, el agente activa un mensaje de fallback, por ejemplo solicitando al usuario reformular la consulta.

Esta estrategia es importante porque mejora la robustez del sistema y evita clasificaciones forzadas. El enunciado también pide justificar el uso de try-except para controlar entradas problemáticas, como texto vacío, consultas mal escritas o casos inesperados, sin que el agente se detenga.

Evaluación

El trabajo debe evaluarse con un conjunto de 20 a 30 consultas variadas, incluyendo errores tipográficos, variaciones lingüísticas y preguntas ambiguas. Asimismo, se exige al menos una métrica cuantitativa de detección de intención, como accuracy o F1-macro, junto con una breve discusión de limitaciones.

En la vista accesible del notebook no se observan todavía los resultados numéricos finales ni el detalle completo de las celdas de implementación. Por esa razón, este informe final resume la metodología, la arquitectura y la justificación técnica del proyecto, dejando pendiente la incorporación explícita de métricas finales, valor de umbral y ejemplos concretos de evaluación en caso de que se desee una versión completamente ajustada a la ejecución final del código.

Relación con los Rrequerimientos del Parcial

El proyecto se alinea directamente con los requerimientos funcionales establecidos por el docente. La propuesta incluye modelado de datos conversacionales, preprocesamiento, representación TF-IDF, detección de intenciones por similitud coseno, extracción básica de entidades, mecanismo de fallback, ejecución local y evaluación cuantitativa.

Requisito	Cumplimiento esperado
RF-01	Intenciones, utterances y respuestas almacenadas en JSON o CSV.
RF-02	Limpieza, tokenización y normalización del texto.
RF-03	Representación de frases con TF-IDF.
RF-04	Detección de intención con similitud coseno.
RF-05	Extracción de entidades con reglas o regex.
RF-06	Umbral de confianza y fallback.
RF-07	Ejecución local por consola o interfaz sencilla.
RF-08	Evaluación con consultas variadas y métricas.

Conclusiones

El agente conversacional propuesto constituye una solución pertinente para centralizar y agilizar la consulta de información frecuente sobre admisión y nivelación de la Universidad de Guayaquil. Desde el punto de vista académico, el proyecto permite aplicar de forma práctica conceptos esenciales del PLN clásico, tales como preprocesamiento textual, representación vectorial, similitud coseno, detección de intenciones y respuestas de fallback.

La propuesta también destaca por separar los datos conversacionales de la lógica del sistema, lo que favorece la claridad del repositorio y la posibilidad de ampliación futura. Como mejora para una versión definitiva de entrega, conviene incorporar en este mismo informe el

número exacto de intenciones implementadas, el valor del umbral utilizado y los resultados cuantitativos obtenidos durante la evaluación del notebook.

Repositorio de Código

https://github.com/Ivn5739/Proyecto_PLN_P2.git